

경희대학교 데이터 분석 동아리



생성모델을 활용한 AI 소설 생성

KoAlpaca Polyglot-ko 12.8B

소프트웨어융합학과 문지원 / devlaonm@gmail.com 컴퓨터공학과 박민아 / alsdkdi0908@gmail.com



<Contents>

1. Why?

2. Data

3. Model

4. Result

5. Discussion





1. Why?

- ChatGPT로 인한 AI 글쓰기에 대한 관심 높아짐.
- 팀원들 모두 평소 소설 창작을 하고 있음.
- => 'AI를 활용한 소설 창작'에 관심을 갖게 됨

"소설 창작에 특화된 인공지능을 개발해 작가로서 유용하게 활용할 수 있지 않을까?" HOME > BIZ > 문화콘텐츠/산업

인간과ChatGPT가함께쓴SF환타지소설'타임시티'출간

음 오석주기자 │ ② 승인 2023.04.19 12:26 │ ◎ 댓글 0

서울을 배경으로 한 기후위기 스토리





1. Why?

그냥 잘 훈련된 pretrained LLM + 대량의 data + Fine tuning면 되지 않나?

- **문제점1)** 잘 훈련된 pretrained LLM -> GPT3 175B?
- 문제점2) 저작권 문제가 없는 데이터?
- 문제점3) Fine tuning?

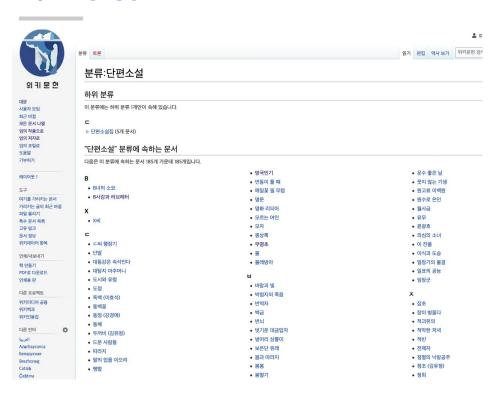


1. Why?

결국 원하는 모든 조건에서 학습하려면 고사양의 GPU가 필요하다! GPU 사양을 높이는 것 말고는 다른 방법이 없을까?

- 데이터가 작더라도 효율적으로 사용해보자.
- 모델의 크기가 비교적 작더라도 한국어로 잘 학습된 모델을 찾아보자.
- Full Fine tuning 말고 다른 방법은 없을까?
 - efficient(lightweight) Fine tuning 사용





저작권이 만료된 한글 소설 찾기

- 위키문헌 "분류:단편소설"
- 네이버 블로그 **"고전소설**" -**〉**2.7MB



적은 양의 데이터를 효과적으로 사용할 방법 필요



저작권이 만료된 한국 소설은 대체로 고전소설/근현대소설

- 현대에는 사용하지 않는 단어가 많음
- 어미 등이 통일되지 않아 학습이 어려움

-> chatgpt를 활용한 문체 변환

제1단 춘향과 이도령

숙종대왕 즉위 초에 성덕이 넙우시사 성자성손은 계계승승하사 금고옥적은 요순시절이요, <mark>의관문물은 우탕의 버금이라. 좌우보필은 주석지신이요, 용양호위는 간성지장이라.</mark> 조정에 흐르는 덕화 향곡 (곡)에 패엿시니 사해굳은 기운이 원근에 어려잇다. 충신은 만조하고 효자열녀 가가재라. 미재미재라 우순풍조하니 함포고복 백성들은 처처에 격양가라.

"전생에 무삼 은혜 찌 ㅎ 1 시 던지 이생에 부부되야 창기행실 다바리고 예모도 숭상하고 여공도 심슷건만 무삼 죄가 진중하야 일점혈육 업섯스니 육친무족 우리 신세 선영향화 뉘라 하며 사후감장 어이하리. 명산대찰에 신고이나 하야 남녀간 나커드면 평생한을 풀 것이니 가군의 뜻이 <mark>어떠하오</mark>." 성참판하는 말이,

"천하대성 공부자도 니구산에 빌으시고, 정나라 정자산은 우성산에 빌어 나계시고, 아동방강산을 이를진댄 명산대천이 업슬손가. 경상도 웅천 주천의는 늙도록 자녀업서 최고봉에 빌엇더니 대명천자 나계시사 대명천지 밝엇스니 우리도 정성이나 듸려보사이다. 공든 탑이 무너지며, 심근 남기 껙길손가."



변환 전

변환 후

한생원은 허연 탑삭부리에 묻힌 쪼글쪼글한 얼굴이 위아래 다섯 대밖에 안 남은 누—런 이빨과 함께 흐물흐물 웃는다.

"그러면 그렇지 글쎄 놈들이 제아무리 영악하기로소니논에다 네 귀탱이 말뚝 박구섬 인도깨비처럼 어여차 어여차 땅을 떠가지구 갈 재주야 있을 이치가 있나요"

한생원은 참으로 일본이 항복을 하였고, 조선은 독립이 되었다는 그날—---팔월 십오일 적보다도 신이 나는 소식이었다. ...(중략)... 팔월 십오일 적에 마을에서는 젊은 사람들이 설도를 하여 태극기를 만들고, 닭을 추렴하고, 술을 사고 하여 놓고 조촐히 만세를 불렀다. 한생원은 그 자리에 참례를 하지 아니하였다. ...(중략)... 한참 농사일이 몰릴 때라도, 내 농사는 손이 늦어도 용길이를 시켜 그들의 논에 모 심고 김 매어 주고 하기. 이 노릇에 흰머리가 도로 검어질

지경이요 빚[債]은 고패가 넘도록 지고 하였다. 하던 것이 인제는 전쟁이 끝이 났으니, 징용 이자는 싹 씻은 듯 없어질 것. 마음 턱 놓고 두 발 쭉 뻗고 잠을 자도 좋았다.

이런 일을 생각하면 한생원도 미상불 다행스럽지 아니한 것은 아니었다. 그러나 오직 그뿐이었다.

독립?

신통할 것이 없었다.

한생원은 가는 기운이 남은 다섯 개의 이빨과 함께 작은 얼굴을 움츠려 웃는다.

"그러면 맞아요. 그렇지만 그들이 얼마나 잔인할지라도 밭에 말뚝을 박아서 일어나지 못하게 하고, 쓸쓸하게 땅을 떠나갈 재주가 있을까요?"

한생원은 참으로 일본이 항복하고, 조선은 독립했다는 팔월 십오일의 소식에 매우 기뻤다. ...(중략)...

팔월 십오일에는 마을에서 <mark>젊은 사람들이 국기를 만들고 닭을 잡고</mark> <mark>술을 마시며</mark> 조용히 만세를 외쳤다.

한생원은 거기서 참여하지 않았다. ...(중략)... 농사가 바쁠 때라도, 자신의 밭은 늦어도 용길이에게 일을 시키고 그들의 땅에 모종을 심어 주는 등의 일을 했다. <mark>이런 일에 시달리면서 머리카락은 흰색으로</mark> 되어갔고 빚은 더욱 늘어갔다.

하지만 이제는 전쟁이 끝났으니, 징용 수당은 없어질 것이다. 마음을 편히 놓고 두 발을 뻗고 잠을 자도 좋았다.

이러한 생각에 한생원은 다행스럽지 않았던 것은 아니었다. 그러나 그것뿐이었다.

독립?

아무 기쁨도 없었다.



데이터 전처리 - 대사와 상황으로 분리

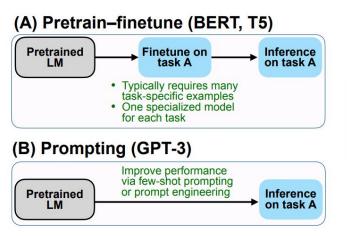
outpu	input	
이러한 메시지를 받은 후에는 그도 그럼직했다. 지난 가을부터	"기왕 을 거면 내가 있을 제 오세요. 왜, 그렇게 어색해할 건가요? 오래간만에 친구 찾아오는 거니까 요. 그런 일 없었다는 걸로 해주세요. 친구 찾아 강남도 가는데 친구 찾아 천리간 오기로 했으니 그 정 도로 번거로워질 건 없잖아요?"	0
훈이가 올라왔다가 A의 메시지를 보고는 이렇게 감정이 솟구쳤다. 그 때도 귀에 솔깃한 소리가 들리는 것을 참았다. 훈이는 여러 해 만에 만나는 친구라는데다가 자신의 작품을 모두 읽은 한 여성이 기다린다는 것이 제 작품에 대한 정당한 평가를 그만두고 듣기 싫은 소리는 아니었다	"뭐, 가보시지요. 오래간만에 친구 만나보는 거니까요. 청초한 아름다운 여자가 기다린다고요 어쩔 수 없잖아요. 그런 중에도 정성스런 팬이 있다니까요"	1
그는 이렇게 이번 여행을 합리화시켜보았다. 그러나 무엇보다도 그를 걸단하게 만든 것은 요즈음 며칠째 삼각형으로 일: 러진 아내의 얼굴이었다. 지난 가을에 집을 쫓겨났을 때는 돈 십 윈 정도 생겼는데 그 때문에 아주 잠깐 선금을 내놓았다! 그 때부터 주인 아내가 한 달 두 달 동안 소 도 이런 모양 저런 모양으로 내려앉기만 하면서 괴로움을 주기 시작했다	"에이구 오랜만이구, 에이구에 찾아가면 한둘 정도는 반색할 사람도 있는 거고, 오래간만에 서울에 가 서 서울 사는 놈이야 별거 있나…"	2
한성이가 입에 익을 만큼 되풀이해온 대답이었다	"김씨, 오늘은 좀 생각해보셔야죠.""그냥 참아야죠."	3
소경이 제 닭 잡아먹는 줄도 모른다는 식으로 그 흐릿한 며칠에 걸쳐 호랑감투를 벌이는 아내는 그의 계획이나 움켜잡듯(따라붙었다	"글쎄, 김씨는 정말 부끄러운 사람이네요 분명히 상황을 알면 면포를 가져올 텐데! 이게 벌써 몇 달 째니까요?"'글쎄, 없는 걸 그렇게 이야기하실 건가요? 다른 사람들처럼 맘도 못 가지고 강도질도 못하 고 말할 만한 곳은 다 막혔으니 어떡합니까? 신문사에서 그 소설을 팔아서 며칠만 더 참으세요!"	4
이렇게 자신감 넘치게 말하며 그는 불어넘겼다. 하지만 달 초일도 지났다. 달 초일만 지나면 그만일 텐데 아내는 이레일! 달 초일처럼 시달렸다	"십일월인 줄 아는데 계속해서 며칠만 계속해서 이렇게 이렇게 하지 말고 제대로 날짜를 말하세 요."'그래요! 아니, 그 날은 안 될 거예요. 한 달 초에 해야지요. 그날은 예전부터 안 묻힌 깨끗한 날짜 로만 드리려고요."	5
는 태도에 끌렸다. 만약 현순이 자신의 파산을 보고 마음이 변해 다른 남자와 거리를 둘 정도로 슬슬 피하게 되거나 자신의 마음이 변한 것을 나타내어 이쪽이 단단히 닫힐 수도 있었다면, 그는 그 자리에서 단념해버릴 수도 있었고, 또 그런 현순이 라면 저쪽에서 목이 마르다고 덤빈다 하더라도 그가 아니었다	"이제 너는 돈이 없어져서 미끄러져라."	6
라고 쏘아붙였을 때도 가늘게 뜬 눈으로 웃음을 지으며 방정식 같이 말한 현순이었다	"그러면 당신은 김한성과 결혼한 것이 아니라 김한성의 재산과 결혼한 것이었던 건가요?"	7

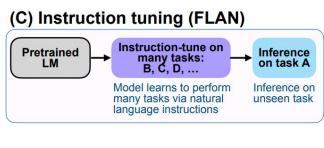
- 큰따옴표를 기준으로 분리
- 한자 및 노이즈 제거

- 연속된 대사 및 상황문 묶기
- 너무 짧은 데이터 삭제, 긴 데이터는 앞 3문장만 사용



- 데이터가 작더라도 효율적으로 사용해보자. 어떻게?
 - -> Instruction tuning을 적용해보자.







data = dataset.map(

다.<|endoftext|>'

Instruction tuning을 소설 생성에는 어떻게 적용할까? -> 대화와 상황으로 분리해보자. 예) "~~""~~""안녕?"(input) / 그는 말했다.(output)

lambda x: {'text': f"### 질문:'다음 문장을 이어쓰시오. ₩n₩n###맥락 : {x['input']}₩n₩n### 답변: {x['output']}<|endoftex

```
[ ] tokenized_datasets['train'][-1]['text']

'### 질문:#'다음 문장을 이어쓰시오. \#n\#n###맥락 : "밤에 조용히 내부 관사로 와서 저도 있을 테니까. 그리고 네 논이 두 개의 논인 거겠군요."\#n\#n### 답변: 두려움에 떨면서 더펄이는 급하게 그 돌을 집어들고 눈을 돌린다. 마구잡이로 가볍게 주먹을 휘둘렀다. 막상 들어있는 금
```

을 보자 얼마든지 팔 수 있을 것 같다는 생각이 들어 그는 즐거워서 흥겨운 춤을 추기 시작한



- 최종 데이터 구성

```
DatasetDict({
    train: Dataset({
        features: ['input', 'output', 'text', 'input_ids', 'token_type_ids', 'attention_mask'],
        num_rows: 7043
    })
    test: Dataset({
        features: ['input', 'output', 'text', 'input_ids', 'token_type_ids', 'attention_mask'],
        num_rows: 1243
    })
})
```

3. Model

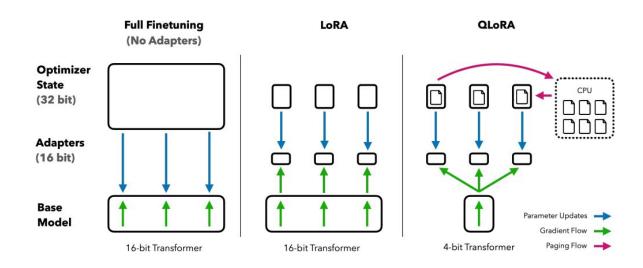
- 조금 작더라도 한국어로 잘 학습된 모델을 사용하자.
- -> KoAlpaca Polyglot-ko 12.8B
 - Alpaca 모델이란?
 - 7B 크기의 LLaMA를 Backbone으로 두고 Instruction tuning을 한 모델

Stanford Alpaca



3. Model

- Full Fine tuning 말고 다른 방법은 없을까?
 - Efficient Finetuning 방법을 찾아보자. -> QLoRA = 4-bit Quantized language model into Low Rank





3. Model

- 모델: KoAlpaca 12.8B
- 학습 환경: Colab pro+ V100 40GB
- 학습 중 GPU 사용률

시스템 RAM 5.8 / 83.5 GB GPU RAM 26.3 / 40.0 GB

디스크 49.5 / 166.8 GB

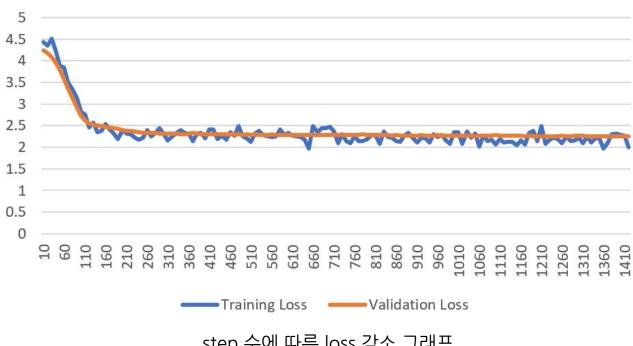
KoGPT6B-ryan1.5b

GPU

The following is the recommended minimum GPU hardware guidance for a handful of example KoGPT.

• 32GB GPU RAM in the required minimum memory size





step 수에 따른 loss 감소 그래프



```
### 질문:
```

맥락 : '아기의 이름은?'

답변: 라고 물었다. 그럼 이 다음에 어떤 남자가 들어오면 어떻게 할 겁니까? 그러면 어떻게 알고 오는 건데. 나는 다시 한 번 대답했다.이번에는 어떤 대답을 할까요?라고 물어왔다. 하지만 아무 대답도 할 수 없었다. 내가 모르는 어떤 사람이 내 이름과 비슷하거나 내가 알고 있는 사람과 비슷한 말이라고 해서 혹시 저 사람이 누구인지 알 수 있을까 하고 물어보면, 그에게는 내가 누구인지도 모르고 있기 때문입니다.그래서 저 사람은 누구인지도 모르는 사람들끼리는 만날 수 없지만, 저 사람이 누군지는 알아야지만, 만날 수 있고 만나기 싫어요. 나는 그사람을 알 수 없지만, 그 사람은 저를 알아요. 그런 의미로 말했던 것이다.그러자 그는 대답했다. 아니, 저 사람들과 저는 다른 사이인데 왜 저 사람들은 만나지 않아도 됩니까? 그리고 왜그들은 나와는 잘 알지 못하는 사람인지 내가 궁금하고 물어본다고 해서 그들은 왜 알게 된 것입니까? 나는 더 이상 물어

checkpoint 100 step



```
### 질문:
```

맥락 : '멀리 떠났다. 느이 누나말이다.'

답변: 내가 결혼을 하려고 했던 때, 우리 집이 너무 가난해지면서 동생의 학비 걱정 때문에 결혼을 하려던 내가 동생의 학비를 대줬다. 이것 때문에 나는 사랑하는 가족도 버리고 여기에 남아 있겠다고 했다. 우리 가족은 아버지의 사업 실패로 점점 어려워지던 그 해에 나를 버리고 서울로 나가려고 했었다. 하지만 결국 아버지는 병이 악화되고 어머니는 약값을 위해 내가 서울로 가는 것을 포기시켰다. 그래서 이 일이 발생했다.....우리 아버지가 이렇게 고생하는 것을 생각하면 우리 가족은 어떻게 되어도 좋단 말이냐! 우리 아버지의 피 때문에 내가 그런 것은 사실이 아니야. 우리 가족이 어떻게 되어도 이런 짓을 한 건 아니야!'

답변: 하고 조용히 말했습니다. 라고 말하며 아내를 바라보면서 고개를 끄덕입니다. 하지만 얼마 후 하고 내 말을 끊는 것이었습니다. 말하며 아내의 손을 잡았습니다. 큰 소리로 말했다. 내 말을 듣고 하며 아내의 어깨에 손을 댔다.

checkpoint 100 step



```
### 질문:
```

맥락 : '아기의 이름은?'

답변: 그도 모르겠다는 듯이 허리를 굽히고 방을 들여다보며, 하다가, 하고 머리를 푹 숙였다. 부인은, 하고,한 줌의 금이 담긴 자루를 들고 방으로 들어갔다. 방에 들어가 보니 상에는 떡 한 접시가 놓여 있고, 그 옆방석 위에는 갓난아이가 쌔근쌔근 잠을 자며 누워 있는데,부인은 아기의 머리맡에 작은 병을 놓고 그 곁에 한 줌의 금을 놓았다. 부인이 한참 동안 잠자고 있는 아이의 얼굴을 들여다보고 있다가 일어서서 나오는 것을 누가 보면,부인이 미친 줄로 생각할 것이다. 그러나 그것은 분명히 사실이다. 그리고 아이도 미친 듯이 울어대었 다. 그도 모르겠다는 듯이 머리를 숙이고 있던 환자가 말했다. 라고,부인이 말했다. 그러 나 그에게는 미친 사람의 말을 듣는다는 것보다 부인이 한 말 자체의 뜻이 더욱 괴이하였다. 한참 동안 말없이 마주앉아 있던 그는, 하다가 말했다. 그렇게 말하고 부인을 바라보니 그

checkpoint 1400 step

5. Discussion

- 더 좋은 GPU, 더 큰 모델, <u>더 많은 데이터</u>가 있었으면 좋았을 것이다.
- 데이터 전처리가 더 필요했던 것 같다.
 - '하고,'의 경우 소설을 대사와 지문으로 나누는 과정에서 남은 잔재로 추정된다.
- Instruction tuning이 제대로 효과가 있었는지 검증을 해보지 못했다.
- efficient tuning을 하는 다양한 방법을 평가해보지 못했다.
- 소설을 생성하는 다양한 방법들을 고려해보았으면 좋았을 것이다.

Thank You

Any Question?

